


2. Bayes統計に基づく推論

Bayesによる確率分布推定の考え方
多項分布、ディリクレ分布
事前分布としてのディリクレ分布の意味
正規分布と事後分布
多次元正規分布と条件付き分布
指数型分布族
自然共役事前分布の最尤推定

by 中川裕志(東京大学)

Bayesによる確率分布推定の考え方

事前分布 とはパラメター
(i.e. μ) 自体の分布




観測データ
or 教師データ: X

$$p(\mu|X) = p(X|\mu) p(\mu)$$

観測データを事前分布にBayes
の定理で組み合わせる

X を観測した後に得た
パラメター μ の
事後分布



パラメター μ は点では
なく、分布として与えら
れる点に注意！

多項分布: *Mult*

- 複数の離散データが独立に出現する場合の確率分布の定番
- 個々の離散データ間に相関がない場合に使うもので基本的分布。
 - 以下は K 種類の離散データ (例えば、語彙数が K で N 単語からなるテキストでの単語の出現分布) がある場合

$$Mult(m_1, m_2, \dots, m_K \mid \boldsymbol{\mu}, N) = \binom{N}{m_1 m_2 \dots m_K} \prod_{k=1}^K \mu_k^{m_k}$$

$$E[m_k] = N\mu_k \quad \text{var}[m_k] = N\mu_k(1 - \mu_k) \quad \text{cov}[m_j, m_k] = -N\mu_j\mu_k$$

ただし、
$$\sum_{i=1}^K \mu_i = 1$$

ディリクレ分布: *Dir*

- 多項分布では離散事象(たとえば単語) i の出現回数 m_i が確率変数だった。
- しかし、逆に m_i が観測値として既知の場合に、単語 i の出現確率 μ_i が確率変数となる分布も考えられる。すなわち、多項分布の事前分布として使えるような分布。


ディリクレ分布: *Dir*

- K変数の場合。 α はパラメータだが、以下の式の分布を作るときに使った既知の観測回数
のデータと考えてもよいだろう。

$$\mu = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_K \end{pmatrix} \quad \alpha = \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_K \end{pmatrix} \quad \sum_{k=1}^K \mu_k = 1 \quad 0 \leq \mu_k \leq 1$$

$$Dir(\mu | \alpha) = \frac{\Gamma(\alpha_1 + \dots + \alpha_K)}{\Gamma(\alpha_1) \dots \Gamma(\alpha_K)} \prod_{k=1}^K \mu_k^{\alpha_k - 1}$$

$$E[\mu_k] = \frac{\alpha_k}{\alpha_1 + \dots + \alpha_K}$$




ディリクレ分布の例

$$\alpha_1 = \alpha_2 = 0.01$$

$$\alpha_1 = \alpha_2 = 1$$

$$\alpha_1 = \alpha_2 = 2$$



$0 \leftarrow \mu_1$
 $1 \leftarrow \mu_2$

$\mu_1 \rightarrow 1$
 $\mu_2 \rightarrow 0$

事前分布としてのディリクレ分布の意味

- ディリクレ分布Dirを事前分布とみなして、観測データが多項分布Multで与えられたときの事後分布としてのディリクレ分布Dirを考える

観測データ i の出現回数 m_i : $X = (m_1, \dots, m_K)$, $\sum_{i=1}^K m_i = M, \sum_{i=1}^K \alpha_i = \alpha_0$

事後 観測 事前

$$Dir(\mu | X, \alpha) \propto Mult(X | \mu) Dir(\mu | \alpha) \propto \prod_{i=1}^K \mu_i^{\alpha_i + m_i - 1}$$

$$\Rightarrow Dir(\mu | X, \alpha) = Dir(\mu | \alpha + X) = \frac{\Gamma(\alpha_0 + M)}{\Gamma(\alpha_1 + m_1) \cdots \Gamma(\alpha_K + m_K)} \prod_{i=1}^K \mu_i^{\alpha_i + m_i - 1}$$

- こうして見ると、 α_i は事前分布を得るために想定した i の (仮想的) 観測回数と見做せる。

正規分布(1変数)と事後分布

- 1変数正規分布: 連続する数値データの確率分布の定番

$$N(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}, \quad E[x] = \mu, \quad \text{var}[x] = \sigma^2$$

- では、ここでMultからDirの事後分布を求めたと同じように、Bayesの定理を用いて、正規分布において、事前分布から事後分布を求めてみよう。

- 次のページの例は簡単のため、分散は既知とし、事後分布の期待値だけを求めることにする。

- 分散の事後分布についてはWishart分布という分布が登場するが、難しいのでここでは省略

事前分布: $p(\mu) = N(\mu | \mu_0, \sigma_0^2)$

K 個の観測データが得られた場合の尤度: $p(X | \mu)$

$$= \prod_{i=1}^K p(x_i | \mu) = \frac{1}{(2\pi\sigma^2)^{K/2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^K (x_i - \mu)^2 \right\} \quad \text{ただし } \sigma \text{ は既知}$$

Bayesの定理が

事後

観測

事前

$$p(\mu | X) \propto p(X | \mu) p(\mu) \propto \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^K (x_i - \mu)^2 - \frac{(\mu - \mu_0)^2}{2\sigma_0^2} \right\}$$

$$\propto \exp \left\{ -\frac{\frac{K}{\sigma^2} + \frac{1}{\sigma_0^2}}{2} \mu^2 + \left(\frac{\mu_0}{\sigma_0^2} + \frac{\sum_{i=1}^K x_i}{\sigma^2} \right) \mu + \dots \right\} \quad \text{--- (N10) } p(\mu | X) \text{ は正規分布}$$

だからこの結果より

$\Rightarrow K$ 個の観測データを得た後の事後分布: $p(\mu | X) = N(\mu | \mu_K, \sigma_K^2)$


$$\frac{1}{\sigma_K^2} = \frac{1}{\sigma_0^2} + \frac{K}{\sigma^2}, \quad \mu_K = \frac{\sigma^2}{K\sigma_0^2 + \sigma^2} \mu_0 + \frac{\sigma_0^2}{K\sigma_0^2 + \sigma^2} \sum_{i=1}^K x_i$$

事前分布からの寄与

観測データからの寄与

観測データ数 K と事後分布の例

$$\sigma_0^2 = 0.1 \quad \sigma^2 = 0.1 \quad \mu_0 = 0 \quad \mu = \frac{1}{K} \sum_{i=1}^K x_i \quad E[x] = 0.5$$



観測データにより事前分布の
パラメータ μ が修正されていく



多次元正規分布

- 多次元正規分布: 複数種類(つまり複数の確率変数)を持つ数値データの確率分布

D 次元の正規分布

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_D \end{bmatrix} \quad \mathbf{E}[\mathbf{x}] = \boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \vdots \\ \mu_D \end{bmatrix}$$

共分散行列 : $\text{cov}[\mathbf{x}] = \boldsymbol{\Sigma} = \begin{bmatrix} \sigma_{11}^2 & & \sigma_{1D} \\ & \ddots & \\ \sigma_{D1} & & \sigma_D^2 \end{bmatrix} = \boldsymbol{\Lambda}^{-1}$: 精度行列

$$\begin{aligned} N(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Sigma}) &= \frac{1}{(2\pi)^{D/2}} \frac{1}{|\boldsymbol{\Sigma}|^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right\} \\ &= \frac{|\boldsymbol{\Lambda}|^{1/2}}{(2\pi)^{D/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Lambda}(\mathbf{x} - \boldsymbol{\mu})\right\} \end{aligned}$$

例題

➤ 多次元正規分布の共分散行列を推定する。

D 次元の正規分布

$$N(\mathbf{x} | \boldsymbol{\mu}, \Lambda^{-1}) = \frac{|\Lambda|^{1/2}}{(2\pi)^{D/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Lambda (\mathbf{x} - \boldsymbol{\mu})\right\}$$

$$\log N(\mathbf{x} | \boldsymbol{\mu}, \Lambda^{-1}) \propto \log |\Lambda| - (\mathbf{x} - \boldsymbol{\mu})^T \Lambda (\mathbf{x} - \boldsymbol{\mu})$$

この対数尤度を最大化するために Λ で微分して0とおく

$$\text{第1項の微分} \quad \frac{\partial \log |\Lambda|}{\partial \Lambda} = (\Lambda^{-1})^T = \Lambda^{-1}$$

$$\begin{aligned} \text{第2項の微分} \quad \frac{\partial (\mathbf{x} - \boldsymbol{\mu})^T \Lambda (\mathbf{x} - \boldsymbol{\mu})}{\partial \Lambda} &= \frac{\partial \text{trace}(\Lambda (\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T)}{\partial \Lambda} \\ &= ((\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T)^T = (\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T \end{aligned}$$

ここで \mathbf{x} に対して期待値をとる、すなわち $E_{\mathbf{x}}[\]$ をすると

$$\Lambda^{-1} - E_{\mathbf{x}}[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T] = 0$$


$$\text{より } E_{\mathbf{x}}[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T] = \Lambda^{-1} = \Sigma$$

条件付正規分布

➤ 変数ベクトル z を x と y に分割すると



$x=a$



➤ 変数ベクトル \mathbf{z} を \mathbf{x} と \mathbf{y} に分割する。

多次元正規分布 $N(\mathbf{z} | \boldsymbol{\mu}, \Sigma)$

$$\mathbf{z} = \begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix} \quad \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{pmatrix} \quad \Sigma = \begin{pmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{pmatrix}$$

$$\text{where } \Sigma = \Sigma^T \quad \Sigma_{xy} = \Sigma_{yx}^T$$

$$\text{精度行列: } \Lambda \equiv \Sigma^{-1} \quad \text{とすると} \quad \Lambda = \begin{pmatrix} \Lambda_{xx} & \Lambda_{xy} \\ \Lambda_{yx} & \Lambda_{yy} \end{pmatrix} \quad \Lambda_{xy}^T = \Lambda_{yx}$$

➤ ここで多次元正規分布の指数の肩の項は次式

$$-\frac{1}{2}(\mathbf{z} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{z} - \boldsymbol{\mu}) =$$

$$-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_x)^T \Lambda_{xx}(\mathbf{x} - \boldsymbol{\mu}_x) - \frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_x)^T \Lambda_{xy}(\mathbf{y} - \boldsymbol{\mu}_y)$$

$$-\frac{1}{2}(\mathbf{y} - \boldsymbol{\mu}_y)^T \Lambda_{yx}(\mathbf{x} - \boldsymbol{\mu}_x) - \frac{1}{2}(\mathbf{y} - \boldsymbol{\mu}_y)^T \Lambda_{yy}(\mathbf{y} - \boldsymbol{\mu}_y)$$

-(G-10)

➤一般に正規分布 $N(\mathbf{z} | \boldsymbol{\mu}, \Sigma)$ の指数の肩は次式で書け、右辺の第1項、第2項の係数の部分に着目すれば期待値、共分散が求まる。

$$-\frac{1}{2}(\mathbf{z} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{z} - \boldsymbol{\mu}) = -\frac{1}{2}\mathbf{z}^T \Sigma^{-1}\mathbf{z} + \mathbf{z}^T \Sigma^{-1}\boldsymbol{\mu} + \text{const} \quad \text{-(G-20)}$$

➤条件付正規分布 $p(\mathbf{x}|\mathbf{y})$ の期待値 $\mu_{\mathbf{x}|\mathbf{y}}$ と共分散 $\Sigma_{\mathbf{x}|\mathbf{y}}$ をこの方法を(G-10)式に適用して求めよう。— 問題

➤ y を定数とみなして x の分布を求めれば、条件付分布になるから(G-10)の第1項の x の2次の項の係数が共分散。すなわち

$$-\frac{1}{2} \mathbf{x}^T \Lambda_{xx} \mathbf{x} \quad \text{により} \quad \Sigma_{x|y} = \Lambda_{xx}^{-1}$$

➤ 一方、(G-10)において \mathbf{x} の1次の項が $\Sigma^{-1} \boldsymbol{\mu}$ これは次式

$$\mathbf{x}^T \{ \Lambda_{xx} \boldsymbol{\mu}_x - \Lambda_{xy} (\mathbf{y} - \boldsymbol{\mu}_y) \}$$

これにより

$$\begin{aligned} \boldsymbol{\mu}_{x|y} &= \Sigma_{x|y} \{ \Lambda_{xx} \boldsymbol{\mu}_x - \Lambda_{xy} (\mathbf{y} - \boldsymbol{\mu}_y) \} \quad \Sigma_{x|y} = \Lambda_{xx}^{-1} \text{より} \\ &= \boldsymbol{\mu}_x - \Lambda_{xx}^{-1} \Lambda_{xy} (\mathbf{y} - \boldsymbol{\mu}_y) \end{aligned}$$

➤ 次に、これらの結果を共分散行列を用いて書き直す

$$\begin{pmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{pmatrix}^{-1} = \begin{pmatrix} \Lambda_{xx} & \Lambda_{xy} \\ \Lambda_{yx} & \Lambda_{yy} \end{pmatrix} \quad \text{において } (Matrix^{-1}) \text{を使えば}$$

$$\Lambda_{xx} = (\Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx})^{-1} \quad \Lambda_{xy} = -(\Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx})^{-1} \Sigma_{xy} \Sigma_{yy}^{-1}$$

⇒

$$\begin{aligned} \boldsymbol{\mu}_{x|y} &= \boldsymbol{\mu}_x + \Sigma_{xy} \Sigma_{yy}^{-1} (\mathbf{y} - \boldsymbol{\mu}_y) \\ \Sigma_{x|y} &= \Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx} \end{aligned}$$

exponential family: 指数型分布族

➤ 事前分布と学習後の事後分布が同一タイプの分布 (事前共役)

$$p(\mathbf{x} | \eta) = h(\mathbf{x}) \exp(\eta^T u(\mathbf{x}) - a(\eta)) \quad (EB1)$$

ただし, $x, u(\mathbf{x}), \eta$ は一般にはベクトル

$$\text{また、} \exp(-a(\eta)) \int h(\mathbf{x}) \exp(\eta^T u(\mathbf{x})) d\mathbf{x} = 1$$

$$a(\eta) = \log \left(\int h(x) \exp(\eta^T u(x)) dx \right) \quad (EB2)$$

正規化項

iidの観測データ $X = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ に対しては以下の式

$$p(\mathbf{X} | \eta) = \left(\prod_{n=1}^N h(\mathbf{x}_n) \right) \exp \left(\eta^T \sum_{n=1}^N \mathbf{u}(\mathbf{x}_n) - Na(\eta) \right)$$

いくつかの確率密度関数のExponential family表現: ガウス分布

$$\begin{aligned} p(x | \mu, \sigma^2) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\} \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{x^2 - 2x\mu + \mu^2}{2\sigma^2}\right\} \\ &= \frac{1}{\sqrt{2\pi}} \exp\left\{\left(\frac{\mu}{\sigma^2}, \frac{1}{\sigma^2}\right) \begin{pmatrix} x \\ -\frac{x^2}{2} \end{pmatrix} - \frac{\mu^2}{2\sigma^2} - \log \sigma\right\} \end{aligned}$$

The diagram illustrates the mapping of the Gaussian distribution parameters to the Exponential family form. Blue boxes and lines identify the components:

- (η_1, η_2) is the natural parameter vector.
- η^T is the natural parameter vector.
- x is the sufficient statistic.
- $a(\eta)$ is the log-partition function.

いくつかの確率密度関数のExponential family表現: 多項分布

多項分布(*Multinomial*)のexponential family表現

$$\begin{aligned} p(x | \mu) &= \binom{N}{x_1 x_2 \cdots x_K} \prod_{k=1}^K \mu_k^{x_k} \quad \sum_{k=1}^K \mu_k = 1, \sum_{k=1}^K x_k = N \text{を使うと} \\ &= \binom{N}{x_1 x_2 \cdots x_K} \exp \left\{ \sum_{k=1}^{K-1} x_k \log \mu_k + \left(N - \sum_{k=1}^{K-1} x_k \right) \left(\log \left(1 - \sum_{k=1}^{K-1} \mu_k \right) \right) \right\} \\ &= \underbrace{\binom{N}{x_1 x_2 \cdots x_K}}_{h(x)} \exp \left\{ \underbrace{\sum_{k=1}^{K-1} \log \left(\frac{\mu_k}{1 - \sum_{k=1}^{K-1} \mu_k} \right)}_{\mu^T} \underbrace{x_k}_{x} + \underbrace{N \left(\log \left(1 - \sum_{k=1}^{K-1} \mu_k \right) \right)}_{a(\mu)} \right\} \end{aligned}$$

自然共役事前分布の最尤推定

$$p(\mathbf{x} | \eta) = h(\mathbf{x}) \exp(\eta^T u(\mathbf{x}) - a(\eta))$$

における natural parameter η の最尤推定をする。

$$1 = \int p(\mathbf{x} | \eta) d\mathbf{x} = \int h(\mathbf{x}) \exp(\eta^T u(\mathbf{x}) - a(\eta)) d\mathbf{x}$$

上の式を η の第 j 成分 η_j で微分してゼロとおくと

$$-\frac{\partial a(\eta)}{\partial \eta_j} \underbrace{\int h(\mathbf{x}) \exp(\eta^T u(\mathbf{x}) - a(\eta)) d\mathbf{x}}_{=1} + \underbrace{\int h(\mathbf{x}) \exp(\eta^T u(\mathbf{x}) - a(\eta)) u(\mathbf{x})_j d\mathbf{x}}_{=E[\mathbf{u}(\mathbf{x})_j]} = 0$$

$$\frac{\partial a(\eta)}{\partial \eta_j} = E[\mathbf{u}(\mathbf{x})_j] \quad (EB3)$$

$$\frac{\partial^2 a(\eta)}{\partial \eta_j^2} = V[\mathbf{u}(\mathbf{x})_j] \quad (EB4)$$

(EB3)(EB4)の応用例

➤ ガウス分布に応用

$$p(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}} \exp \left\{ \left(\frac{\mu}{\sigma^2}, \frac{1}{\sigma^2} \right) \begin{pmatrix} x \\ -\frac{x^2}{2} \end{pmatrix} - \frac{\mu^2}{2\sigma^2} - \log \sigma \right\}$$

$$\eta^T = (\eta_1, \eta_2) \quad x \quad a(\eta) = - \left(\frac{\eta_1^2}{2\eta_2} - \frac{1}{2} \log \eta_2 \right)$$

$$E_{\eta_1}[x] = \frac{\partial a(\eta)}{\partial \eta_1} = \frac{\partial}{\partial \eta_1} \frac{\eta_1^2}{2\eta_2} = \frac{\eta_1}{\eta_2} = \mu \quad V_{\eta_1}[x] = \frac{\partial^2 a(\eta)}{\partial \eta_1^2} = \frac{\partial}{\partial \eta_1} \frac{\eta_1}{\eta_2} = \frac{1}{\eta_2} = \sigma^2$$

(EB3)(EB4)の応用例 多項分布に応用

$$h(x) \quad \eta_k = \log\left(\frac{\mu_k}{1 - \sum_{k=1}^{K-1} \mu_k}\right) \quad x \quad a(\eta)$$

$$p(x | \mu) = \binom{N}{x_1 \cdots x_K} \prod_{k=1}^K \mu_k^{x_k} = \binom{N}{x_1 \cdots x_K} \exp\left\{ \sum_{k=1}^{K-1} \log\left(\frac{\mu_k}{1 - \sum_{k=1}^{K-1} \mu_k}\right) x_k + N \log\left(1 - \sum_{k=1}^{K-1} \mu_k\right) \right\}$$

$$e^{\eta_k} = \frac{\mu_k}{1 - \sum_{k=1}^{K-1} \mu_k} \quad \sum_{k=1}^K e^{\eta_k} = \frac{\sum_{k=1}^K \mu_k}{1 - \sum_{k=1}^{K-1} \mu_k} = \frac{1}{1 - \sum_{k=1}^{K-1} \mu_k} \quad a(\eta_k) = -N \log\left(1 - \sum_{k=1}^{K-1} \mu_k\right) = -N \log \frac{1}{\sum_{k=1}^K e^{\eta_k}} = N \log \sum_{k=1}^K e^{\eta_k}$$

$$\frac{\partial a(\eta_k)}{\partial \eta_k} = N \frac{e^{\eta_k}}{\sum_{k=1}^K e^{\eta_k}} = N \frac{\frac{\mu_k}{1 - \sum_{k=1}^{K-1} \mu_k}}{\sum_{k=1}^K \frac{\mu_k}{1 - \sum_{k=1}^{K-1} \mu_k}} = N \frac{\mu_k}{\sum_{k=1}^K \mu_k} = N \mu_k$$

$$\frac{\partial^2 a(\eta_k)}{\partial \eta_k^2} = \frac{\partial N \frac{e^{\eta_k}}{\sum_{k=1}^K e^{\eta_k}}}{\partial \eta_k} = N \frac{e^{\eta_k} \left(\sum_{k=1}^K e^{\eta_k} \right) - e^{\eta_k} e^{\eta_k}}{\left(\sum_{k=1}^K e^{\eta_k} \right)^2} = N \frac{e^{\eta_k} \left(\sum_{k=1}^K e^{\eta_k} - e^{\eta_k} \right)}{\left(\sum_{k=1}^K e^{\eta_k} \right)^2} = N \frac{\frac{\mu_k}{1 - \sum_{k=1}^{K-1} \mu_k} \left(\frac{1 - \mu_k}{1 - \sum_{k=1}^{K-1} \mu_k} \right)}{\left(1 - \sum_{k=1}^{K-1} \mu_k \right)^{-2}} = N \mu_k (1 - \mu_k)$$

➤ 2項分布の場合はおなじみの公式

$$p(x|\eta) = \binom{N}{x} \mu^x (1-\mu)^{N-x} = \binom{N}{x} \exp \left\{ x \log \frac{\mu}{1-\mu} + N(\log(1-\mu)) \right\}$$

$$h(x) \quad \eta = \log \left(\frac{\mu}{1-\mu} \right) \quad a(\eta)$$

$$e^\eta = \frac{\mu}{1-\mu} \quad e^\eta(1-\mu) = \mu \quad e^\eta = \mu(1+e^\eta) \quad \mu = \frac{e^\eta}{1+e^\eta}$$

$$a(\eta) = -N \log(1-\mu) = -N \log \left(\frac{1}{1+e^\eta} \right) = N \log(1+e^\eta)$$

$$\boxed{E_\eta[x]} = \frac{\partial a(\eta)}{\partial \eta} = N \frac{e^\eta}{1+e^\eta} = N\mu \quad \boxed{V_\eta[x]} = \frac{\partial^2 a(\eta)}{\partial \eta^2} = \frac{\partial}{\partial \eta} N \frac{e^\eta}{1+e^\eta} = N \frac{e^\eta}{(1+e^\eta)^2} = N\mu(1-\mu)$$

Exponential familyとベイズ統計: 共役分布と事後分布

ハイパーパラメター: $\lambda = (\lambda_1^T, \lambda_2)$ によって共役事前分布を定義する

$$p(\eta | \lambda) = h(\eta) \exp \left\{ \lambda_1^T \eta + \lambda_2 (-a(\eta)) - a(\lambda) \right\}$$

$$a(\lambda) = \log \left(\int h(\eta) \exp \left\{ \begin{pmatrix} \lambda_1^T, \lambda_2 \end{pmatrix} \begin{pmatrix} \eta \\ -a(\eta) \end{pmatrix} \right\} d\eta \right) \quad (EB22)$$

さて、 $p(x | \eta)$ に沿う K 個の*iid*の観測データ $x_1 \cdots x_K$ が得られたときの η の事後分布は

$$p(\eta | x_1, \dots, x_N, \lambda) \propto p(\eta | \lambda) \prod_{i=1}^K p(x_i | \eta) \\ \propto h(\eta) \exp \left\{ \lambda_1^T \eta + \lambda_2 (-a(\eta)) - a(\lambda) \right\} \prod_{i=1}^K \exp \left\{ \eta^T u(x_i) - a(\eta) \right\}$$

$$\propto h(\eta) \exp \left\{ \left(\lambda_1 + \sum_{i=1}^K u(x_i) \right)^T \eta + \left(\lambda_2 + K \right) (-a(\eta)) - a(\lambda) \right\}$$

赤枠の中は事後パラメター

仮想的な観測データ

実際の観測データ

仮想的な観測回数:1

実際の観測回数

1変数正規分布の期待値に適用した例 その1

$$\text{事前分布: } p(\mu | \lambda) = N(\mu | \mu_0, \sigma_0^2) \quad \lambda = (\lambda_1, \lambda_2)^T, \lambda_1 = \frac{\mu_0}{\sigma_0^2}, \lambda_2 = \frac{1}{2\sigma_0^2}$$

$$p(\mu | \lambda) = N(\mu | \mu_0, \sigma_0^2) \propto \exp\{\lambda_1 \mu - \lambda_2 a(\mu) - a(\lambda)\} = \exp\left\{\frac{\mu_0}{\sigma_0^2} \mu - \frac{\mu^2}{2\sigma_0^2} - \frac{\mu_0^2}{2\sigma_0^2}\right\}$$

K 個の観測データが得られた場合の尤度: $p(X | \mu)$

$$= \prod_{i=1}^K p(x_i | \mu) = \frac{1}{(2\pi\sigma^2)^{K/2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^K (x_i - \mu)^2\right\} \quad \text{ただし } \sigma \text{ は既知}$$

$$p(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}} \exp\left\{\underbrace{\left(\frac{\mu}{\sigma^2}, \frac{1}{\sigma^2}\right)}_{\eta^T} \underbrace{\begin{pmatrix} x \\ -\frac{x^2}{2} \end{pmatrix}}_{a(\eta)} - \frac{1}{2} \underbrace{\left(\frac{\mu^2}{\sigma^2} + \log \frac{1}{\sigma^2}\right)}_{a(\eta)}\right\}$$

$\mu_0, \sigma_0^2, \sigma^2$ は既知とする。

1変数正規分布の期待値に適用した例 その2

$$p(\mu | x_1, \dots, x_N, \lambda) \propto p(\mu | \lambda) \prod_{i=1}^K p(x_i | \mu)$$

$$\propto h(\eta) \exp\{\lambda_1 \mu - \lambda_2 a(\mu)\} \prod_{i=1}^K \exp\{\eta^T u(x_i) - a(\eta)\}$$

$$\eta^T = \left(\frac{\mu}{\sigma^2}, \quad \frac{1}{\sigma^2} \right)$$

$$\propto h(\eta) \exp \left\{ \lambda_1 \mu + \left(\sum_{i=1}^K x_i, \sum_{i=1}^K \frac{x_i^2}{2} \right) \begin{pmatrix} \frac{\mu}{\sigma^2} \\ \frac{1}{\sigma^2} \end{pmatrix} - \lambda_2 a(\lambda) - K a(\eta) \right\}$$

$$\propto h(\eta) \exp \left\{ \mu \frac{\mu_0}{\sigma_0^2} + \mu \frac{1}{\sigma^2} \sum_{i=1}^K x_i - \frac{\mu^2}{2\sigma_0^2} - \frac{K}{2} \left(\frac{\mu^2}{\sigma^2} + \log \frac{1}{\sigma^2} \right) \right\}$$

$$\propto \exp \left\{ \mu \left(\frac{\mu_0}{\sigma_0^2} + \frac{1}{\sigma^2} \sum_{i=1}^K x_i \right) - \frac{\mu^2}{2} \left(\frac{1}{\sigma_0^2} + \frac{K}{\sigma^2} \right) \right\}$$

←前に求めた N10 に一致

K 個の観測データも考慮したハイパーパラメター

$$\hat{\lambda}_1 = \lambda_1 + \sum_{i=1}^K u(x_i) \quad (EB21)$$

$$\hat{\lambda}_2 = \lambda_2 + K \quad (EB22)$$

ハイパーパラメターが与えられたときの事後分布は次式のように η でmarginalize

$$p(x | \lambda) = \int p(x | \eta) p(\eta | \lambda) d\eta$$

$$= h(x) \int \exp \{ \eta^T u(x) - a(\eta) \} h(\eta) \exp \{ \lambda_1^T \eta + \lambda_2 (-a(\eta)) - a(\lambda) \} d\eta$$

$$= h(x) \int h(\eta) \exp \{ (\lambda_1 + u(x))^T \eta + (\lambda_2 + 1)(-a(\eta)) \} d\eta \exp \{ -a(\lambda) \} \quad (EB23)$$

\Rightarrow ハイパーパラメター λ と

K 個の*iid*の観測データ $x_1 \dots x_K$ が得られたときの

新規 (あるいは未知) の x の予測分布は(EB23)において

$$\lambda_1 \text{ を } \hat{\lambda}_1 = \lambda_1 + \sum_{i=1}^K u(x_i) \text{ で}$$

$$\lambda_2 \text{ を } \hat{\lambda}_2 = \lambda_2 + K \text{ で}$$

置き換えれば得られる。

ベイズ統計による事前、事後、予測分布の例：多変数ガウス分布
難しいので省略する予定

精度行列(分散の逆行列) Λ が既知の d 次元ガウス分布を exponential family で表現

$$\begin{aligned} p(x | \eta) &= \frac{1}{2} (2\pi |\Sigma|)^{-\frac{d}{2}} \exp \left\{ -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right\} \quad \Lambda = \Sigma^{-1} \quad \text{とおくと} \\ &= \exp \left\{ -\frac{1}{2} \left(d \log 2\pi + d \log |\Lambda| + (x - \mu)^T \Lambda (x - \mu) \right) \right\} \\ &= \exp \left\{ -\frac{1}{2} \left(d \log 2\pi + d \log |\Lambda| + x^T \Lambda x - x^T \Lambda \mu - \mu^T \Lambda x + \mu^T \Lambda \mu \right) \right\} \end{aligned}$$

natural parameter : η がまだ決めていなかった!

$$\Rightarrow \eta = \Lambda \mu \quad \text{以下も注意} \quad \Lambda^T = \Lambda \quad (\Lambda^{-1})^T = \Lambda^{-1} \quad \mu = \Lambda^{-1}$$

$$p(x | \eta) = \exp \left\{ -\frac{1}{2} \left(d \log 2\pi + d \log |\Lambda| + x^T \Lambda x \right) \right\} \exp \left\{ \eta^T x - \frac{1}{2} \eta^T \Lambda^{-1} \eta \right\}$$

$h(x)$

$u(x) = (x_1, \dots, x_d)^T$

$a(\eta)$

事前分布のパラメータ λ から予測分布 $p(x \mid \lambda)$ を求める

$$\begin{aligned} p(\eta \mid \lambda) &\propto \exp \left\{ \lambda_1^T \eta + \lambda_2 a(\eta) - a(\lambda) \right\} = \exp \left\{ \lambda_1^T \eta - \lambda_2 \frac{1}{2} \eta^T \Lambda^{-1} \eta - a(\lambda) \right\} \\ &= \exp \left\{ -\frac{1}{2} \left(\eta^T \lambda_2 \Lambda^{-1} \eta - 2 \lambda_1^T \eta + 2 a(\lambda) \right) \right\} \text{事前分布もガウス分布として} \\ &= \exp \left\{ -\frac{1}{2} \left(\left(\eta - \frac{\Lambda \lambda_1}{\lambda_2} \right)^T \lambda_2 \Lambda^{-1} \left(\eta - \frac{\Lambda \lambda_1}{\lambda_2} \right) \right) \right\} \text{とおくと} \\ &\propto \exp \left\{ \frac{1}{2} \log |\lambda_2 \Lambda^{-1}| - \frac{1}{2} \left(\eta^T \lambda_2 \Lambda^{-1} \eta - 2 \lambda_1^T \eta + \frac{\lambda_1^T \Lambda \lambda_1}{\lambda_2} \right) \right\} \\ \Rightarrow a(\lambda) &= -\frac{1}{2} \left(d \log \lambda_2 + \log |\Lambda^{-1}| \right) + \frac{1}{2} \frac{\lambda_1^T \Lambda \lambda_1}{\lambda_2} \end{aligned}$$

$$\because d\text{次元の行列}\Lambda^{-1}\text{に対しては、}|\lambda_2 \Lambda^{-1}| = \lambda_2^d |\Lambda^{-1}|$$

$$p(\eta | \lambda) = h(\eta) \exp \left\{ \lambda_1^T \eta + \lambda_2 (-a(\eta)) - a(\lambda) \right\}$$

$$a(\lambda) = \log \left(\int h(\eta) \exp \left\{ \begin{pmatrix} \lambda_1^T, \lambda_2 \end{pmatrix} \begin{pmatrix} \eta \\ -a(\eta) \end{pmatrix} \right\} d\eta \right) \quad (EB22) \quad \text{および}$$

(EB3)(EB4)より λ が与えられたときの η の十分統計量が以下のように求まる。

$$E[\eta] = \frac{\partial a(\lambda)}{\partial \lambda_1} = \frac{(\Lambda + \Lambda^T) \lambda_1}{2 \lambda_2} \quad (EB35) \quad E[-a(\eta)] = \frac{\partial a(\lambda)}{\partial \lambda_2} = \frac{d}{2 \lambda_2} - \frac{\lambda_1^T \Lambda \lambda_1}{\lambda_2^2} \quad (EB36)$$