

ノンパラメトリックベイズ

モデルの複雑さが不明な場合


- これまでに説明してきたK-means、EM、変分ベイズなどは、モデルの複雑さ、たとえばクラスタリングにおけるクラスタ数は予め分かっているとしてモデル推定した。
- しかし、実際はクラスタ数が不明の場合が多い。

ノンパラメトリックとは

- 観測データに応じてモデル自体の複雑さも学習する
 - クラスタリングの場合は、クラスタ数が予め分かっていない場合。観測データに適したクラスタ数も推定

データから学習するということの直観

$$p(x | \theta, \pi) = \sum_{k=1}^K \pi_k N(x | \theta_k) \quad (NP1)$$



- 有限個の正規分布を配分比 π_k での混合モデル:式(NP1)
- クラスタ数 K の値を観測データから最適化することによって推定する。
- 基本的アイデア:無限次元の連続分布から観測データに適応した有限次元の離散分布を学習する。

無限次元からサンプリングして 有限次元へ

$$G_0 \quad \Rightarrow \quad p(x | \theta, \pi) = \sum_{k=1}^{\infty} \pi_k N(x | \theta_k) \quad (NP2)$$

$$\Rightarrow \quad p(x | \theta, \pi) = \sum_{k=1}^K \pi_k N(x | \theta_k) \quad (NP1)$$

- 基底測度という連続の確率分布 G_0 から無限次元の離散基底分布 (NP2) で近似し、そこから有限次元の離散分布 $G(NP1)$ を推定する。


連続ドメインの基底測度 G_0





連続ドメインの基底測度を
➤ 可算無限次元の
離散分布 (NP2)
で近似して事前分布
とする。



有限次元離散分布
(NP1)
➤ 観測データから推
定



この密度は、 G_0 の
密度分布に比例



Chinese Restaurant Process

観測データが到着するごとに無限次分布 NP_2 からクラスタを生成していくにあたって、以下の2者択一


- 新しく生成 → G_0 に近い
- 既にあるクラスタに追加 → 観測データへの追従性

これによって、 G_0 に観測データを組み合わせた事後分布を得る



→ Chinese Restaurant Process

G_0 への近さを表すパラメターを集中度パラメター (concentration parameter) α_0 とする。

イメージは次のスライドを参照



Z_1



....





$$\frac{1}{\alpha_0 + 1}$$



$$\frac{\alpha_0}{\alpha_0 + 1}$$

1のテーブル
につく確率

残ったテーブルのうちの一つにつく確率(ただし、
次の候補のテーブルは θ_2 に決まっているとす
る。)




$$\frac{2}{\alpha_0 + 2}$$



$$\frac{2}{\alpha_0 + 3}$$


テーブル
につく確率



$$\frac{\alpha_0}{\alpha_0 + 2}$$



$$\frac{1}{\alpha_0 + 3}$$



$$\frac{\alpha_0}{\alpha_0 + 3}$$

....

$N+1$ 人目が k のテーブルに着く確率 $p(Z_{N+1} = k | Z_1, \dots, Z_N)$

N 人目までに着席したテーブル数 $= K$

テーブル k に着席した人数を n_k とすると

$$p(Z_{N+1} = k | Z_1, \dots, Z_N) = \begin{cases} \frac{n_k}{\alpha_0 + N} & (k = 1, \dots, K) \\ \frac{\alpha_0}{\alpha_0 + N} & (k = K + 1) \end{cases}$$


➤ α_0 が大きいほど、無限次元の分布 G_0 に近い

➤ α_0 が小さいほど、観測データに追従した
事後分布となる

➤ テーブルをクラスタとみなすと、着席しているテーブルの数が観測データから推定されたクラスタ数

[Ferguson, 1973]

- 基底測度 G_0 においてドメイン $\Omega=[0,1]$ 上の分割 $\{A_i\}_{i=1}^K$ の確率測度: $G(A_i)$



分割 A_i をどのように作るかはまだ分かっていない

$$(G(A_1), G(A_2), \dots, G(A_K)) \sim \text{Dir}(\alpha_0 G_0(A_1), \alpha_0 G_0(A_2), \dots, \alpha_0 G_0(A_K))$$

$$G \sim DP(\alpha_0, G_0) \quad G \propto \prod_{i=1}^K \theta_i^{x_i-1}, \quad x_i \propto \alpha_0 G_0(A_i)$$

$$\theta \sim G \quad \theta = (\theta_1, \dots, \theta_K)$$

$A \sim B(\phi)$ は、 B という生成過程でパラメータ ϕ を用いて A という分布が生成されるという意味

$\alpha_0 G_0(A_i)$ に比例する回数の sampling によって離散分布化し x_i を得る

x_i を用いて、ディリクレ分布の確率変数 θ_i の値を得る


DPの構成定理

[Sethuraman, 1994]

$G \sim DP(\alpha_0, G_0)$ は
 $\theta \sim G_0, \pi_k > 0, \sum_{k=1}^{\infty} \pi_k = 1$ を用いて

分割 A_i に対応する配分比 π_i

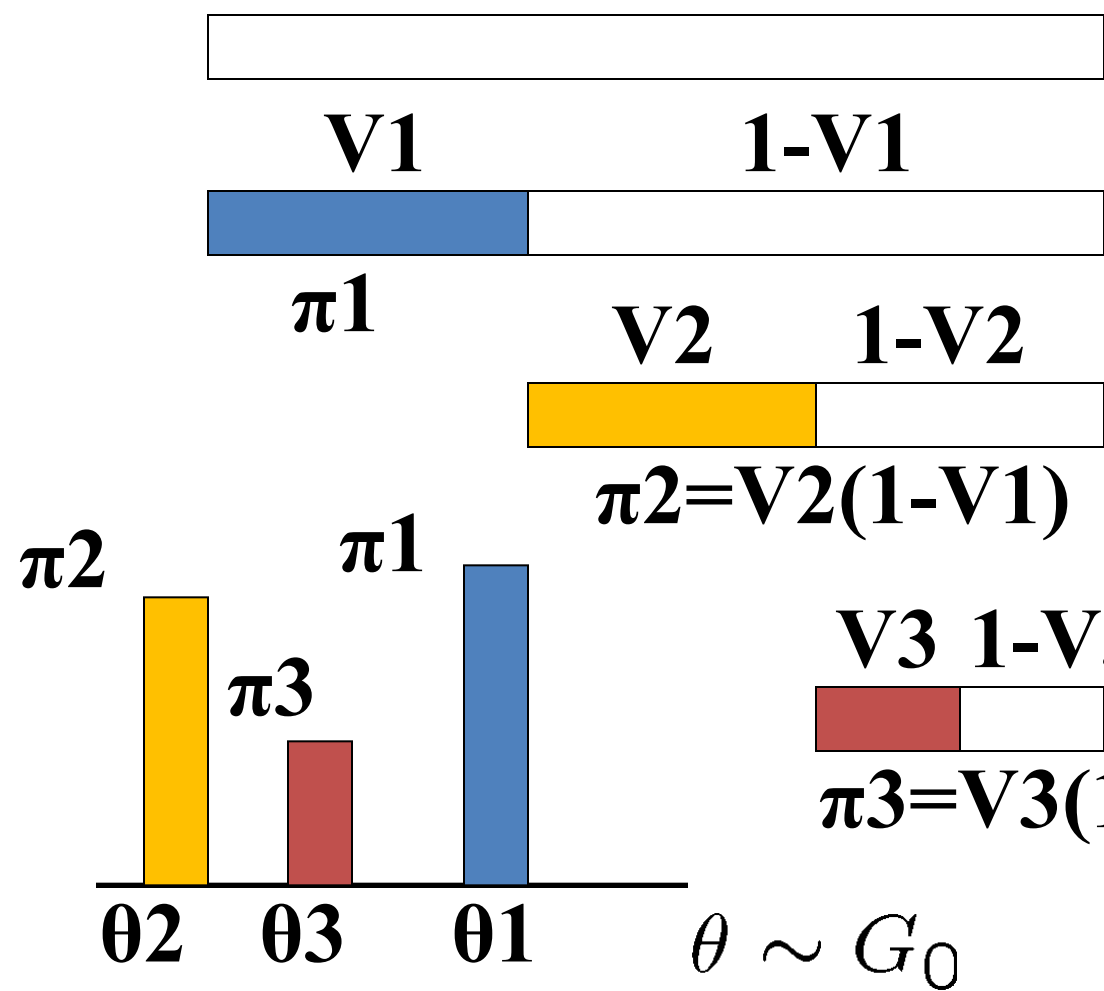
$G(\theta) = \sum_{k=1}^{\infty} \pi_k \delta_{\theta^k}(\theta)$ と構成可能



➡ 配分比 π_i は次に述べる
Stick-breaking Processで実現可能

Stick-breaking Process

- 長さ1の棒(stick)の切断(breaking)



$$V_i \sim \text{Beta}(1, \alpha)$$

$$\pi_k = V_k \prod_{i=1}^{K-1} (1 - V_i)$$

Beta(1, α)

$$\begin{aligned} \text{Beta}(\mu \mid a, b) &= \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \mu^{a-1} (1-\mu)^{b-1} \\ &= \text{Dirichlet}(\mu_1, \mu_2 \mid a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \mu_1^{a-1} \mu_2^{b-1} \end{aligned}$$

$$\mu_1 + \mu_2 = 1$$

$$\text{Beta}(\mu \mid 1, \alpha) = \frac{\Gamma(1+\alpha)}{\Gamma(1)\Gamma(\alpha)} (1-\mu)^{\alpha-1}$$

連続ドメインの基底測度 G_0




連続ドメインの基底測度を
➤ 可算無限次元の
離散分布 G
で近似して事前分布
とする。



有限次元離散分布

➤ 観測データから推定



```
while 収束するまで以下を繰り返す do
  for n in randperm (1, . . . ,N) do
     $X_n$  をクラスタ(古い)  $Z_n$  から削除してパラメータを更新
     $Z_n \sim p(Z_n|X, Z_{-i})$  をサンプル(新しい  $Z_n$ )
     $X_n$  をクラスタ  $Z_n$  に追加してパラメータを更新
  end for
end while
 $Z_1, \dots, Z_N$  を出力
```

ギブスサンプリングによる z_n の推定.
 $\text{randperm}(x)$ は x のランダムな並び換えを表す.

Dirichlet 分布の事後分布

$$P(\boldsymbol{\pi} | \{x_i\}_{i=1}^N) \propto P(\{x_i\}_{i=1}^N | \boldsymbol{\pi}) P(\boldsymbol{\pi})$$

Multinomial分布

π の事前分布は
Dirichlet分布

$$\boldsymbol{\pi} | \{x_i\}_{i=1}^N \sim \text{Dir}(\mu'_1, \dots, \mu'_K)$$

$$\mu'_i = \frac{\alpha_0 \mu_i + n_i}{\alpha_0 + N} \quad n_i \text{ は観測データにおける } i \text{ の出現回数}$$

Dirichlet 分布の事後予測分布

$$P(x_{N+1} | \{x_i\}_{i=1}^N) = \int P(x_{N+1} | \boldsymbol{\pi}) P(\boldsymbol{\pi} | \{x_i\}_{i=1}^N) d\boldsymbol{\pi}$$

$$\begin{aligned} P(x_{N+1} = x^j | \{x_i\}_{i=1}^N) &= \int P(x_{N+1} = x^j | \boldsymbol{\pi}) P(\boldsymbol{\pi} | \{x_i\}_{i=1}^N) d\boldsymbol{\pi} \\ &= \int \pi_j P(\boldsymbol{\pi} | \{x_i\}_{i=1}^N) d\boldsymbol{\pi} \\ &= \mu'_j = \frac{\alpha_0 \mu_j + n_j}{\alpha_0 + N} \end{aligned}$$

$$= \frac{\alpha_0}{\alpha_0 + N} \mu_j + \frac{N}{\alpha_0 + N} \sum_{i=1}^N \frac{\delta_j(x_i)}{N}$$

Dirichlet Processの事後予測分布

[Blackwell and MacQueen, 1973]

$$P(\theta_{N+1} | \{\theta_i\}_{i=1}^N) = \int P(\theta_{N+1} | G) P(G | \{\theta_i\}_{i=1}^N) dG$$

$$= G' = \frac{\alpha_0}{\alpha_0 + N} G_0 + \frac{N}{\alpha_0 + N} \sum_{i=1}^N \frac{\delta_{\theta^j}(\theta_i)}{N}$$




新たにサンプリングされる確率

$$\theta_{N+1} | \{\theta\}_{i=1}^N \sim \begin{cases} G_0 & \left(\frac{\alpha_0}{\alpha_0 + N} \right) \\ \sum_{i=1}^N \frac{\delta_{\theta^j}(\theta_i)}{N} & \left(\frac{N}{\alpha_0 + N} \right) \end{cases}$$

既存の θ が選ばれる確率

離散有限次元 ドメイン

連続無限次元 ドメイン



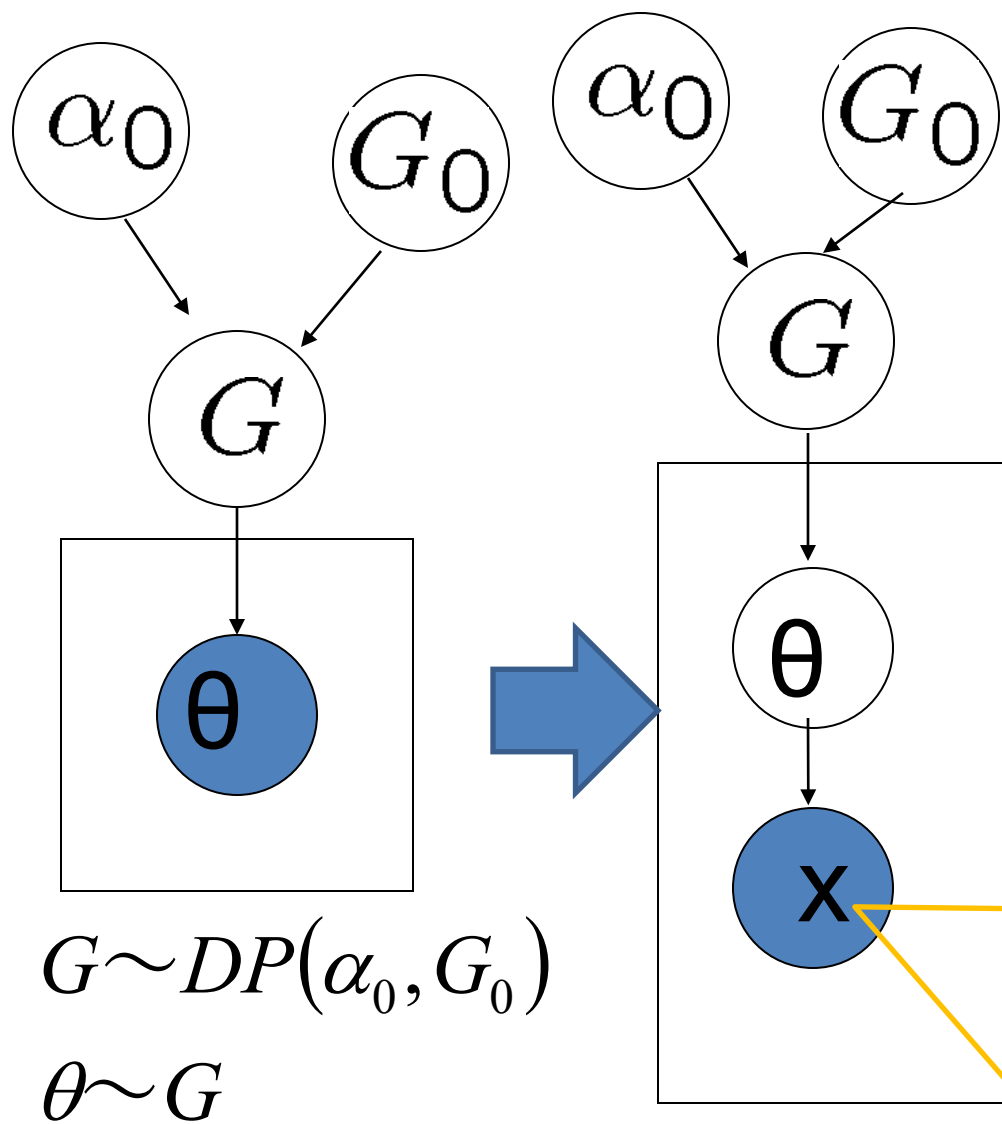
$$G \propto \prod_{i=1}^K \theta_i^{x_i-1}$$

$$\pi \sim \text{Dir}(\alpha_0, \mu) \quad \mu = (\mu_1, \dots, \mu_K)$$

$$x \sim \text{Multi}(\pi) \propto \prod_{i=1}^K \pi_i^{x_i} \quad x = (x_1, \dots, x_K)$$

$$G \sim \text{DP}(\alpha_0, G_0)$$

$$\theta \sim G$$



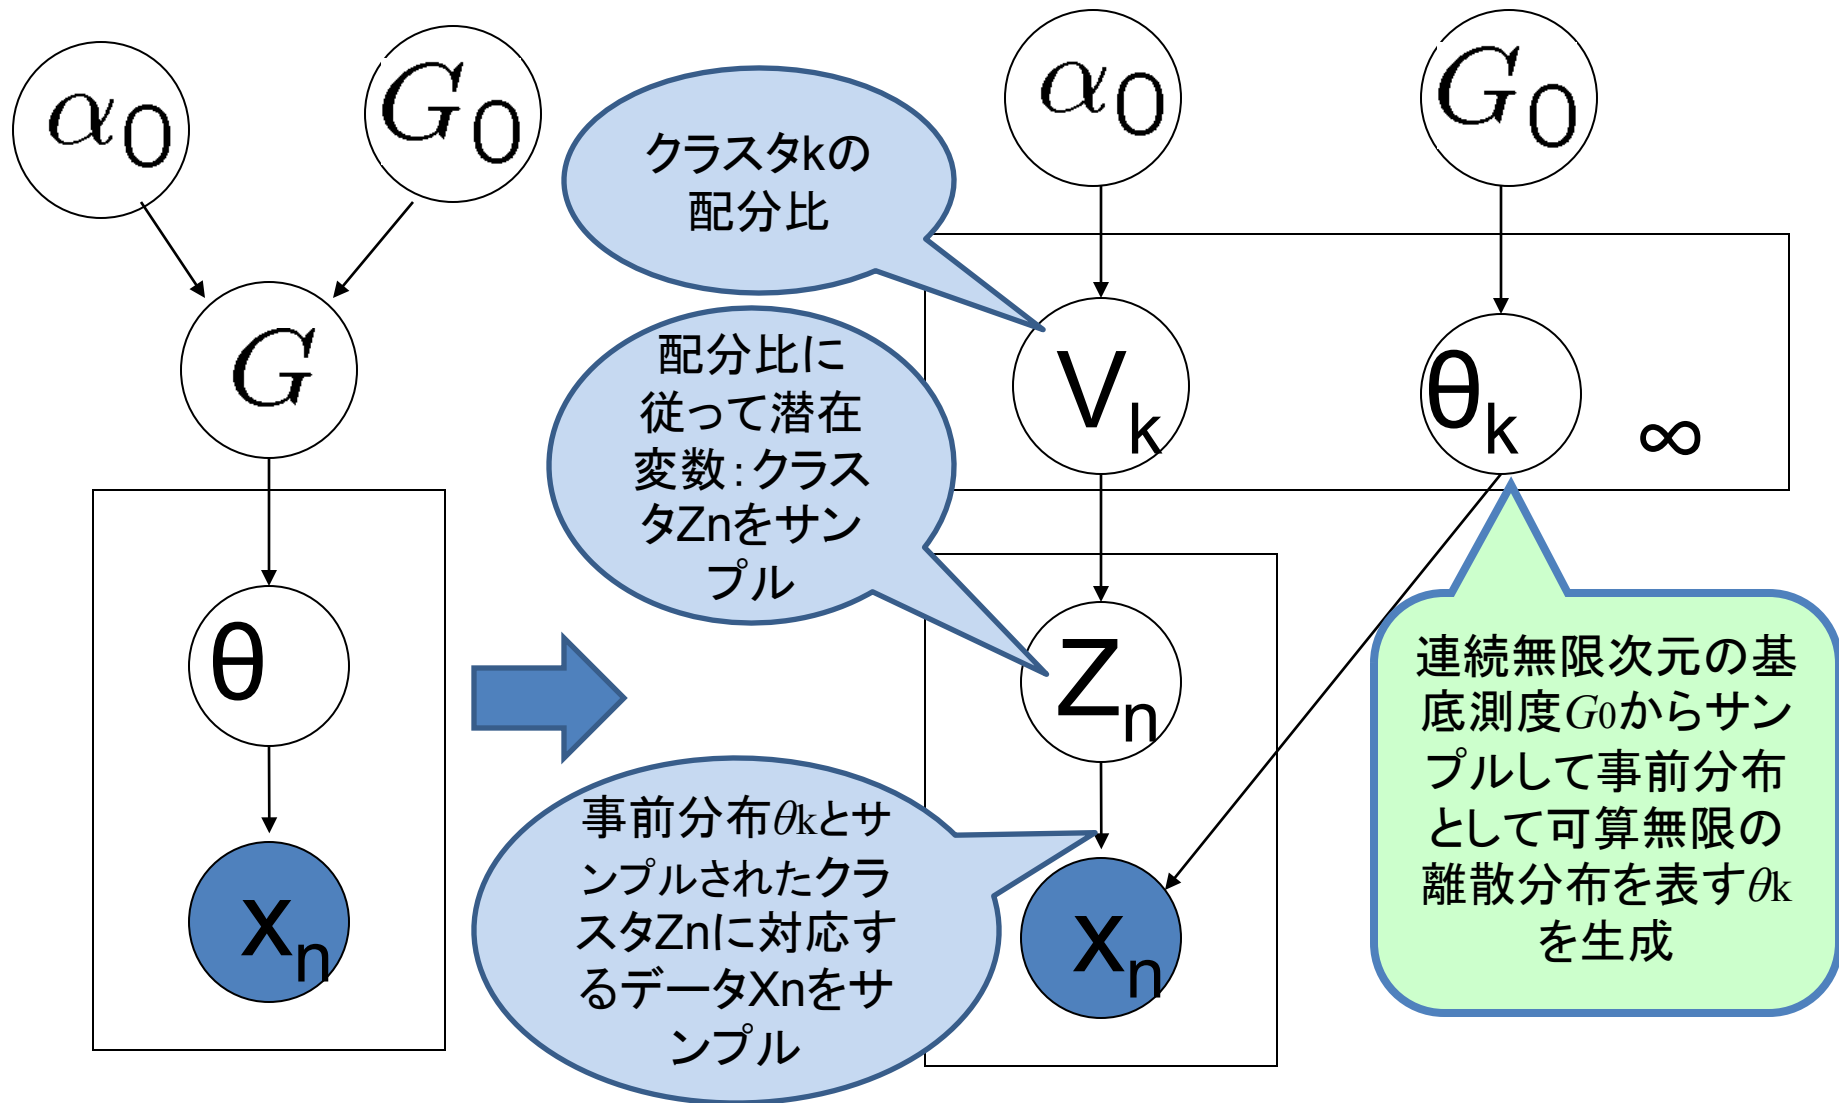
Dirichlet 混合過程

$$G \sim DP(\alpha_0, G_0)$$

$$\theta \sim G \propto \prod \theta_i^{x_i - 1}$$

$$x \sim P(x | \theta) \propto \prod \theta_i^{x_i}$$

- このようにして得た θ は事前分布。
- X は観測データからサンプルして、 θ などのパラメータの推定を収束するまで繰り返す(ex. Gibbs Sampling)
- しかし、観測データを考慮して事後分布にする推論方法はまだ分からない
→そこでStick Breaking



$$G \sim DP(\alpha_0, G_0) \quad V \sim Beta(1, \alpha_0)$$

$$\theta \sim G$$

$$\theta \sim G_0$$

$$x_n \sim P(x|\theta)$$

$$x_n \sim p(x|Z_n, \theta)$$

Dirichlet 過程

- Chinese Restaurant Process や混合正規分布の混合比： π_i ($i=1, \dots, \infty$) は、離散分布
- 離散分布で一般的なMultinomial あるいはその事前分布のDirichlet分布で考えていく。

$$\text{Mult}(m_1, m_2, \dots, m_K \mid \boldsymbol{\mu}, N)$$

$$= \binom{N}{m_1 m_2 \dots m_K} \prod_{k=1}^K \mu_k^{m_k}$$

$$\mathbb{E}[m_k] = N\mu_k$$

$$\text{var}[m_k] = N\mu_k(1 - \mu_k)$$

$$\text{cov}[m_j, m_k] = -N\mu_j\mu_k$$

$$\text{ただし、} \quad \sum_{i=1}^K \mu_k = 1$$

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_K \end{pmatrix} \quad \boldsymbol{\alpha} = \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_K \end{pmatrix}$$

$$\sum_{k=1}^K \mu_k = 1 \quad 0 \leq \mu_k \leq 1$$

$$\text{Dir}(\boldsymbol{\mu} \mid \boldsymbol{\alpha}) = \frac{\Gamma(\alpha_1 + \dots + \alpha_K)}{\Gamma(\alpha_1) \dots \Gamma(\alpha_K)} \prod_{k=1}^K \mu_k^{\alpha_k - 1}$$

$$\mathbb{E}[\mu_k] = \frac{\alpha_k}{\alpha_1 + \dots + \alpha_K}$$

参考文献

- [1]Sethuraman. A Constractive Definition of Dirichlet Prior. Statistica Sinica (4), 639-650. 1994
- [2]持橋大地. 最近のベイズ理論の進展と応用 (III) ノンパラメトリックベイズ. 電子情報通信学会論文誌 (to be published)